◎ 논 문

2023-2 연구논문

# CarMaker 환경에서 최적 성능 달성을 위한 강화학습 기반 운전자 모델 개발

† 한재웅

# Developing a Reinforcement Learning-based Driver Model for Achieving Optimal Performance in the CarMaker Environment

† Jaewoong Han

*Key Words : Vehicle Simulation(차량 시뮬레이션), Reinforcement Learning(강화학습), CarMaker(카메이커), IPG Driver(IPG 드라이버), Python(파이썬)*

## ABSTRACT

This study explores the application of reinforcement learning in vehicle dynamics simulation, particularly focusing on overcoming the limitations of the existing IPG Driver Model in CarMaker environment. The main objective is to develop a driver model using reinforcement learning to create a model that simulates realistic vehicle control, demonstrating significant performance improvements in dynamic handling scenarios. This indicates a notable advancement over the existing IPG Driver model, specially in terms of efficiency and responsiveness in vehicle handling. The study underscores the potential of reinforcement learning in vehicle simulation, offering a more precise and realistic alternative to existing models. The findings suggest that this approach can contribute to the advancement of automotive simulation technologies, particularly in scenarios requiring complex dynamic control.

## 1. 서 론

차량 연구 분야에서 차량 시뮬레이션의 역할은 점점 중요해지고 있다. 이러한 맥락에서 차량 동역학 시뮬레이션 프로그램인 독일 IPG Automotive 사의 CarMaker는 차량의 성능을 정밀하게 고려할 수 있는 강력한 도구로 자리를 잡고 있다. CarMaker는 차량의 다양한 동적 특성을 정밀하게 모사할 수 있는 기능을 갖추고 있으며, 이를 통해 자동차 설계 및 테스트에 있어 중요한 역할을 한다. 사용자는 차량, 도로 상태 등의 변수를 설정한다. 그리고 이 변수에 따라 CarMaker 내부의 IPG 운전자 모델을 이용하여 차량 주행 결과를 확인할 수 있다. 또한, CarMaker는 MATLAB/ Simulink를 통해 차량을 사용자가 직접적으로 조종할 수 있기 때문에 차량 시뮬레이션 분야에서 적극적으로 활용되고 있다.

그러나, IPG 운전자 모델이 제공하는 동역학 모델은 몇 가지 한계를 지니고 있는데, 그중 횡 방향 차량 동역학 제어에서 뚜렷한 한계가 드러난다. 이러한 한계는 차량 성능을 평가하는 테스트 과정에서 두드러지게 나타난다. 예를 들어, 실제 차량 시험에서 성공적으로 통과한 횡 방향 테스트 시나리오에서 IPG 운전자 모델은 실패하는 사례가 발견되었다.[(1)] 이는 IPG 운전자 모델의 정밀도와 현실 적용 가능성에 대한 간극을 보여주며, CarMaker 내의 환경을 IPG 운전자의 동역학 모델이 적절히 활용하지 못한다는 점을 시사한다. 따라서, 현실 차량 테스트 환경을 정밀하게 모사하기 위해서는 IPG 운전자 모델의 한계를 극복할 수 있는 새로운 접근 방식이 필요함을 암시한다.

본 연구는 이러한 문제를 해결하기 위해 강화학습 기반의 새로운 운전자 모델을 개발하고자 한다. 강화학습은 머신러닝의 한 분야로, 에이전트가 환경과 상호작용하면서 보상을 최대화하는 방향으로 행동을 학습하는 과정이다. 강화학습을 이용하면 실제 운전자의 반응과 유사한 방식으로 차량을 제어할 수 있는 모델을 개발할 수 있으며, 이를 통해 더 정밀하고 현실적인 시뮬레이션 결과를 얻을 수 있을 것으로 기대된다.

본 연구의 목적은 CarMaker 환경에서 적용 가능한 강화학습 기반 운전자 모델을 개발하고, 이를 기존의 IPG 운전자 모델과 비교 평가하여 성능을 뛰어넘는 결과를 도출하는 것이다. 특히, 횡 방향 차량 동역학 제어 성능 비교를 위해 차량 핸들링 시나리오를 통해 비교할 예정이다. 또한, Rear Wheel Steering (RWS) 시스템을 포함하는 다양한 차량 핸들링 시나리오에 대한 적용 가능성을 탐구할 예정이다. RWS는 후륜 조향 시스템으로, 차량의 주행 상황에 따라 능동적으로 후륜 조향각을 제어하는 기술이다. 이를 통해 다양한 task에서도 적용 가능하며 IPG 운전자 모델의 횡 방향 차량 동역학 제어 성능을 뛰어넘는 강화학습 기반 운전자 모델을 개발하고자 한다.

## 2. 연구 방법

### 2.1 CarMaker - Python 데이터 송수신

본격적으로 강화학습 모델을 제작하기 전, CarMaker의 차량 동역학 모델을 직접적으로 제어함과 동시에 시뮬레이션 결과를 받아올 수 있도록 설계해야 한다. 이를 위해 MATLAB의 Simulink를 이용하였다. 또한, Simulink의 송수신 결과를 TCP/IP 소켓 통신을 이용하여 데이터를 python에서 직접적으로 관리할 수 있도록 제작하였다.[2] 정리하자면, 다음과 같다.

(1) Python에서 차량 제어 값을 TCP/IP 소켓을 통해 송신
(2) Simulink에서 (1)의 값을 TCP/IP 소켓을 통해 수신
(3) Simulink에서 (2)의 값을 CarMaker로 송신
(4) CarMaker에서 (3)의 값을 수신
(5) (4)의 데이터를 이용하여 CarMaker내에서 시뮬레이션 진행
(6) CarMaker에서 (5)의 시뮬레이션 결과 데이터 중 Python에서 필요로 하는 데이터를 Simulink로 송신
(7) Simulink에서 (6)의 값을 TCP/IP 소켓을 통해 송신
(8) Python에서 (7)의 값을 TCP/IP 소켓을 통해 수신

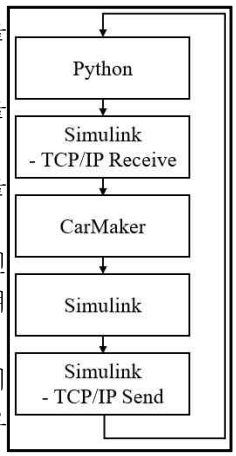

그림 1. 통신 구조도

이때, CarMaker와 Simulink의 데이터는 CarMaker 자체에서 제공하는 CarMaker4SL 라이브러리를 이용하여 데이터를 주고받는다.

### 2.2 강화학습 모델 선정

CarMaker의 연속적인 행동 공간에서 차량을 제어하기 위해 다양한 강화학습 모델의 적용에 관한 사례를 살펴보면, Kuttil., et al (2019)[4]은 A2C (Advantage Actor Critic) 알고리즘을 이용하여 차량의 종 방향 제어 성능을 개선하였다. 한편, Mao Li, Li & Li (2022)[5]에 따르면, A2C와 유사하지만 off-policy 알고리즘을 사용하는 최근에 개발된 SAC의 성능이 우수함이 증명되었다. 따라서 본 연구에서는 SAC 모델을 사용하였다.

Soft Actor-Critic(SAC)는 연속적인 값인 상태(state)에 해당하는 시뮬레이션 데이터, 행동(action)에 해당하는 차량 제어 값에서 효과적으로 사용 가능한 알고리즘이다. SAC 모델은 Actor, Critic 두 가지의 네트워크를 사용하여 학습을 진행하며, 로봇 공학과 같은 복잡한 환경에서 효과적인 학습이 가능한 모델로 밝혀져 있다.[6] 그 이유는 다음과 같다.[3]

(1) Actor 네트워크

Actor 네트워크의 주된 목적은 주어진 상태에 대해 어떤 행동을 취할지 결정하는 것이다. 이 네트워크는 현재 환경의 상태를 입력으로 받아, 이에 대응하는 행동을 출력한다. Actor 네트워크의 목적함수는 다음과 같다:

$$J(\pi) = \sum_{t=0}^{T} \mathbb{E}_{(s_t,a_t)\sim\rho_\pi}\Big[r(s_t,a_t)+\alpha\mathcal{H}(\pi(\cdot|S_t))\Big]$$

Actor 네트워크의 목적함수는 정책(policy)의 성능을 최대화하는 것이다. 이때, SAC는 엔트로피 보상을 포함한 목적함수를 사용한다. 각 항은 다음과 같은 의미를 지닌다.

(a) $\mathbb{E}_{(s_t,a_t)\sim\rho_t}$: 기대값 연산자로, 정책 $\pi$에 따라 분포 $\rho_\pi$에서 샘플링된 상태-행동 쌍에 대한 기댓값을 의미한다.

(b) $r_{(s_t,a_t)}$: 시간스텝 $t$ 에서 상태 $s_t$와 행동 $a_t$를 취했을 때 받는 즉각적인 보상을 의미한다.

(c) $\mathcal{H}(\pi(\cdot|S_t))$: 엔트로피 항으로, 정책의 불확실성을 나타낸다. 이를 통해 알고리즘이 탐험을 장려하도록 한다. 높은 엔트로피는 더 많은 탐험을 의미하며, 낮은 엔트로피는 더 결정적인 행동을 의미한다.

(d) $\alpha$: 엔트로피 가중치로, 정책의 확률적 특성을 얼마나 중요시할지 결정한다.

Actor 네트워크의 목적은 최대의 목적함수를 갖는 것이다. 따라서, 시간에 걸쳐 기대되는 반환 값을 최대화하는 동시에, 정책의 엔트로피를 증가시켜 탐험을 장려한다. 특히, 이러한 엔트로피의 특성 때문에 복잡한 환경에서 자주 사용되는 강화학습 모델이다.

(2) Critic 네트워크

Critic 네트워크의 주요 목적은 특정 정책에 따른 행동의 가치를 평가하는 것이다. 즉, 특정 상태에서 특정 행동을 취할 때 기대할 수 있는 반환 값(return)을 예측한다.

$$J_Q(\theta) = \mathbb{E}_{(\mathbf{s}_t,\mathbf{a}_t)\sim\mathcal{D}}\left[\frac{1}{2}\left(Q_\theta(\mathbf{s}_t,\mathbf{a}_t) - \hat{Q}(\mathbf{s}_t,\mathbf{a}_t)\right)^2\right]$$

Critic 네트워크의 목적함수는 정책에 따른 행동의 가치를 정확하게 추정하는 것이다. 각 항은 다음과 같은 의미를 지닌다.

(a) $Q_\theta(s_t,a_t)$: 파라미터 $\theta$를 가진 critic 네트워크가 추정하는 상태 $s_t$에서 행동 $a_t$를 취했을 때의 가치이다.

(b) $\hat{Q}(s_t,a_t)$: 타깃 가치로, 일반적으로 실제 보상과 다음 상태에서의 가치 추정을 바탕으로 계산된다.

(c) $\mathbb{E}_{(\mathbf{s}_t,\mathbf{a}_t)\sim\mathcal{D}}$: 경험 리플레이 버퍼 $\mathcal{D}$에서 생성된 샘플링 데이터에 대한 기대값이다.

Critic 네트워크의 목적은 추정된 Q-값과 타깃 Q-값 사이의 평균 제곱 오차를 최소화하여, 실제 반환 값을 정확하게 예측하는 것이다. 이를 통해 Actor 네트워크가 보다 정확한 기대 반환값에 따라 행동을 선택하도록 한다. 특히, 경험 리플레이 버퍼를 사용하는 off-policy 기법을 이용하여 이전의 정책에서 얻은 경험도 학습에 재사용 함으로써 학습의 효율을 높인다.

2.3 강화학습 환경 제작

2.3.1 코드별 구조

2.1 CarMaker 차량 직접 제어 결과를 토대로 강화학습 환경을 제작하였다. 코드는 크게 세 가지로 구성된다.

(1) Train: stable-baselines3 모듈의 SAC 모델을 이용하여 학습을 진행하는 코드이다.

(2) CarMakerEnv: gymnasium의 Env를 이용하여 제작된 custom 환경이다. CMControlNode를 통해 데이터를 주고받는다.

(3) CMContro Node: 2.1 CarMaker 차량제어에서 구현한 데이터 송수신을 담당하는 코드이다.

각 코드의 작동 방식은 그림 2와 같다.

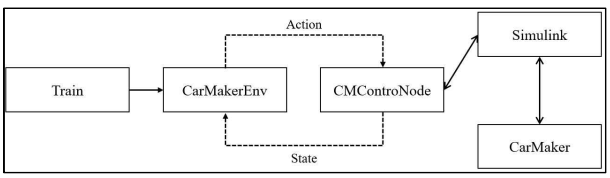


그림 2. 코드 구조도

Train 코드를 통해 SAC로 구성된 모델이 학습을 시작하면, CarMakerEnv 환경에서 선택된 행동 값을 CMControlNode 내부의 TCP/IP 소켓을 통해 Simulink로 송신한다. 이 값은 CarMaker로 전송되며, 시뮬레이션이 진행된다. 시뮬레이션 결과 중 강화학습 환경의 상태에 필요한 값을 Simulink가 수신하여 TCP/IP 소켓을 통해 CMControlNode로 송신한다. 이 값을 CarMakerEnv 환경에서 보상을 계산하여 학습이 진행된다.

2.3.2 강화학습 환경

강화학습 환경을 담당하는 CarMakerEnv의 상태, 행동, 보상은 아래와 같다:

(1) 행동: 횡 방향 차량 동역학 제어를 위해 차량의 조향각 변화량(difference in steering angle)을 제어하며, -0.15에서 +0.15의 값을 가질 수 있다.

(2) 상태: 차량에 대한 정보와 전방 경로(look ahead trajectory)를 상태정보로 활용한다. 각 항에 대한 설명은 아래와 같다:

(a) 차량 정보: 속도, 요(yaw), 조향각 및 조향 각속도, 바퀴별 조향각

(b) 전방 경로: 전방 2 m, 4 m, 6 m, 8 m, 10 m, 12 m 지점 경로의 상대좌표 값

추가로, 2.3에서 구현한 RWS 차량의 경우 뒷바퀴 조향각에 대한 추가적인 정보를 상태 값으로 제공하였다.

(3) 보상: 차량의 중심과 경로 간 떨어진 거리 및 각도의 합을 보상으로 제공하였다.

2.3 RWS 시스템 적용 차량 구현

RWS 시스템을 구현하여 CarMaker 차량의 후륜 조향각을 제어하기 위해 MATLAB/Simulink를 이용하였다.

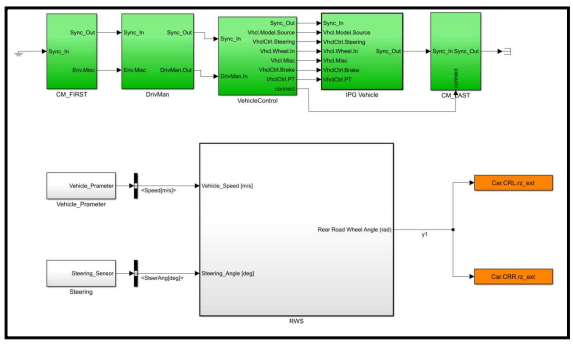


그림 3. RWS 시스템 적용

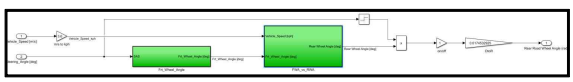

그림 4. RWS 시스템 적용 (RWS박스)

그림 3은 MATLAB/Simulink에서 RWS 시스템을 구현한 그림이며, 그림 4는 그림 3의 중앙 회색의 RWS 박스 부분의 내부 모습이다. 차량의 속도를 고려하여 뒷바퀴 조향각을 제어하도록 설계되었다.

2.4 테스트 시나리오 선정 및 제작

핸들링 시험에 대한 차량의 적합성을 확인하기 위하여 30 m Slalom과 ISO 3888-2(Double Lane Change)의 규격에 맞춰 그림 5 및 그림 6과 같이 코스를 구성하였으며, 표1과 표 2의 세팅에 맞추어 그림 7 및 그림 8과 같이 시뮬레이션을 수행하였다.[1] 추가로, ISO 3888-2의 경우 IPG 운전자 모델과 RWS 시스템 적용 차량 및 RWS 시스템 미적용 차량 세 가지에 대해 비교하였다.

| Slalom | 세팅 | |
|---|---|---|
| 차량 | Hyundai Ionic | |
| 초기속도 | 50 kph | |
| Manuever* | Longitudinal Dynamics | Lateral Dynamics |
| 0 m ~ | Speed Control, 50 kph | Not Specified |

표 1. Slalom 테스트 시나리오 세팅

| ISO 3888-2 | 세팅 | |
|---|---|---|
| 차량 | Hyundai Palisade | |
| 초기속도 | 50 kph | |
| Manever | Longitudinal Dynamics | Lateral Dynamics |
| 0 m ~ 52 m | Speed Control, 50 kph | Not Specified |
| 52 m ~ 111 m | Manaul, G/B/C/P 0, 0.2 | |
| 111 m ~ | Speed Control, 50 kph | |

표 2. ISO 3888-2 테스트 시나리오 세팅

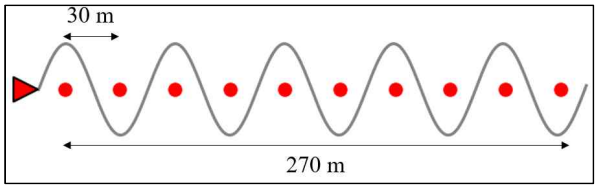


그림 5. Slalom 테스트 시나리오 코스

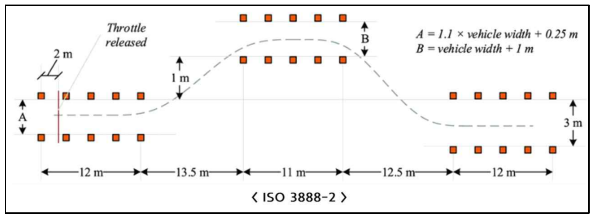


그림 6. ISO 3888-2 테스트 시나리오 코스

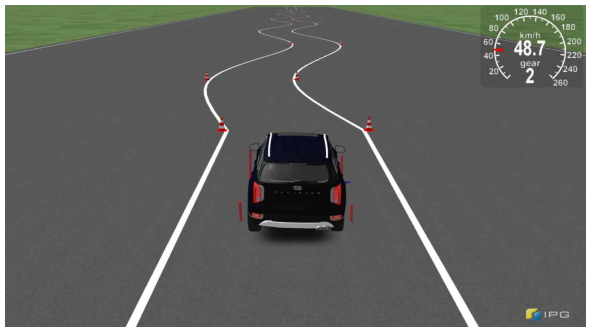


그림 7. Slalom 테스트 시나리오 시뮬레이션

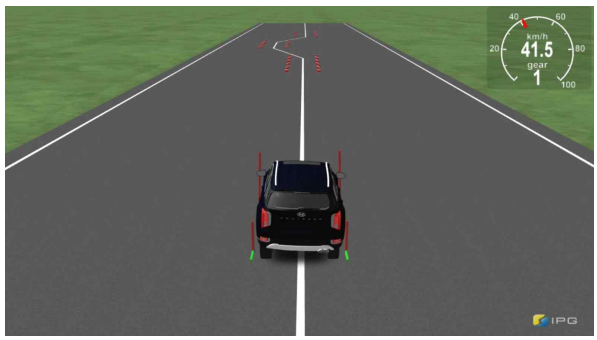


그림 8. ISO 3888-2 테스트 시나리오 시뮬레이션

두 테스트 시나리오에 대한 공통적인 목표는 운전자 모델과 강화학습 운전자 모델의 차량 경로를 비교하는 것이다. 각 시나리오의 세부 목표는 아래와 같다:

(1) Slalom: 콘과의 충돌이 일어나지 않으면서 차량의 움직임을 최소화하는, 즉, 횡 방향 움직임을 최소화하는 것을 목표로 한다.

(2) ISO 3888-2: 콘과의 충돌수를 최소화하는 것을 목표로 한다.

* Manuever는 CarMaker 내에서 차량의 종 방향, 횡방향 역학에 대해 설정하는 기능이다.

## 3. 연구 결과

각 테스트 시나리오별 300 만회의 학습을 진행하였다. 그 결과는 다음과 같다.

### 3.1 SLALOM 테스트 시나리오 결과 및 결과 분석

SLALOM 테스트 시나리오에서의 차량 경로를 운전자 모델과 강화학습 모델의 이동 경로와 Y축 이동량을 비교한 결과는 다음과 같다.

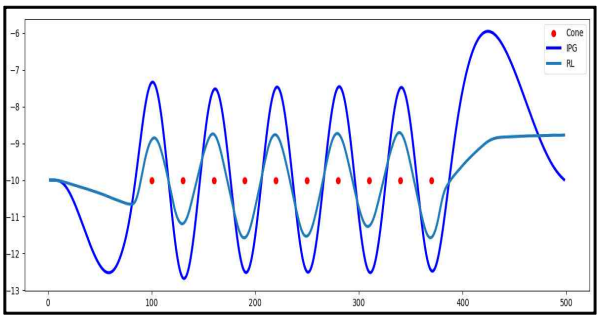


그림 9. Slalom 테스트 시나리오 차량 이동 경로

| 운전자 모델 | y축 이동량 (m) |
|---|---|
| IPG | 64 |
| 강화학습 | 29 |
| 비교 (%) | 54 |

표 3. Slalom 테스트 시나리오 y축 이동량 비교

### 3.2 ISO 3888-2 (Double Lane Change) 테스트 시나리오 결과

3888-2 테스트 시나리오에서의 차량 경로를 운전자 모델과 강화학습 모델의 이동 경로는 다음과 같다. 빨간색 원은 차량이 콘과 충돌했음을 의미한다.

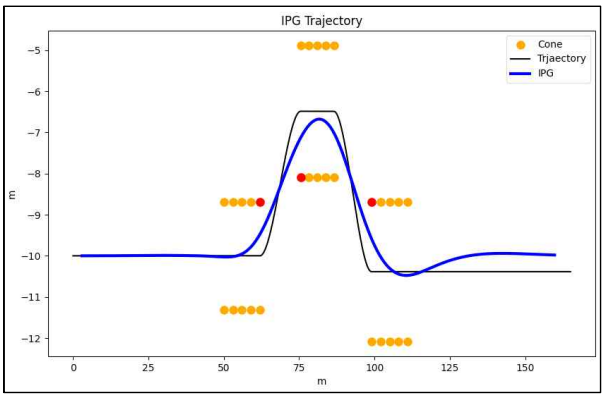


그림 10. ISO 3888-2 테스트 시나리오 IPG 운전자 모델 이동 경로

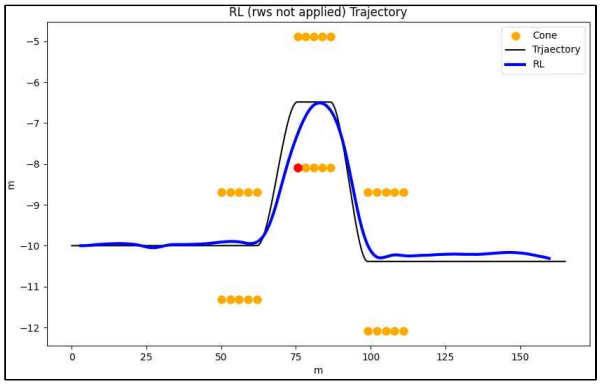


그림 11. ISO 3888-2 테스트 시나리오 RWS 시스템 미적용 강화학습 운전자 모델 이동 경로

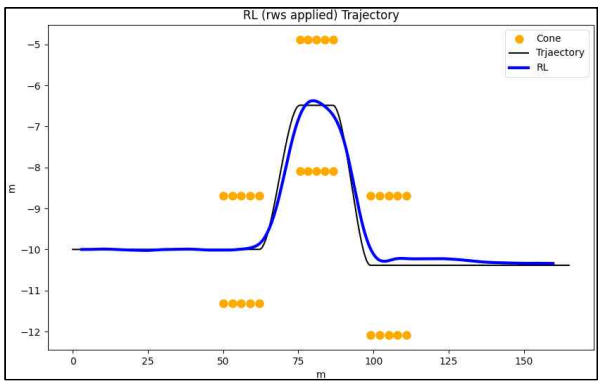


그림 12. ISO 3888-2 테스트 시나리오 RWS 시스템 적용 강화학습 운전자 모델 이동 경로

그림 10, 11, 12는 각 차량의 움직임에 대한 경로이며, 빨간색 원은 해당 위치의 콘과 충돌했음을 의미한다. 결과는 표4와 같다.

| 운전자 모델 | 충돌 횟수 | 충돌 지점 |
|---|---|---|
| IPG | 3 | (62, -8.685), (75.5, -8.085), (99, -8.685) |
| 강화학습 - RWS 미적용 | 1 | (75.5, -8.085) |
| 강화학습 - RWS 적용 | 0 | - |

표 4. ISO 3888-2 시나리오 콘 충돌 비교

IPG 운전자 모델의 경우 세 개의 콘과 충돌하였으며, RWS 시스템이 미적용된 강화학습 운전자 모델의 경우 한 개의 콘과 충돌하였다. 마지막으로, RWS 시스템이 적용된 강화학습 운전자 모델의 경우 충돌하지 않았다.

## 4. 토의

이 연구는 CarMaker 환경에서 다양한 task에서 적용 가능한 강화학습 기반 운전자 모델을 개발하고, IPG 운전자 모델의 횡 방향 차량 동역학 제어 성능을 뛰어넘는 강화학습 기반 운전자 모델을 개발하였다. 연구 결과는 다음과 같다.

(1) Slalom 테스트 시나리오에서 IPG 운전자 모델은 상대적으로 불필요한 횡 방향 움직임이 나타나는 것으로 관찰되었다. 반면, 강화학습 운전자 모델은 횡 방향 움직임이 횡방향 움직임을 최소화한 것을 확인할 수 있다. 이러한 차이는 y축 이동량 비교에서 더 명확히 드러난다. 또한, IPG 운전자 모델은 64 m의 y축 이동량을 보인 반면, 강화학습 운전자 모델은 29 m의 y축 이동량을 보였다. 이는 강화학습 운전자 모델이 IPG 운전자 모델에 비해 약 54 % 더 효율적인 횡 방향 제어를 달성했음을 의미한다.

(2) ISO 3888-2(Lane Change) 테스트 시나리오에서 강화학습 기반 운전자 모델이 IPG 운전자 모델보다 콘 충돌 횟수가 적은 것을 확인할 수 있었다. 또한, RWS가 적용된 차량이 미적용된 차량에 비해 콘 충돌을 적게 하며 더 우수한 성능을 입증하였다. 또한, 이동 경로에서도 세 개의 운전자 모델은 차이를 보인다. 먼저, IPG 운전자 모델의 경우 Lane Change 구간인 62 m ~ 75.5 m, 86.5 m ~ 99 m 지점에서 급격한 조향각 제어에 대응하지 못하고 충돌하는 모습을 보인다. 그러나, 강화학습 운전자 모델의 경우 이에 대응하는 모습을 보인다. 특히, RWS 시스템이 적용된 차량의 경우 완벽히 대응하는 것을 확인할 수 있다. 즉, 뒷바퀴 조향으로 인해 차량 움직임에 제약이 감소하며 차량 횡 방향 제어에 더 효과적인 모습을 확인할 수 있다.

본 연구에서 개발된 강화학습 기반 운전자 모델의 성능은 기존 IPG 운전자 모델을 상당히 능가하는 것으로 나타났다. 이는 강화학습 모델이 다양한 상황에서 최적의 반응을 도출할 수 있는 능력을 갖추고 있기 때문이다. 또한, 본 연구는 RWS 시스템 적용, 서로 다른 차종 적용 등 다양한 task에서도 성공적으로 적용 가능한 강화학습 모델을 개발하였다는 점에서도 의의가 있다.

향후 연구에서는 강화학습 모델의 학습 과정과 파라미터 최적화 방안에 대한 더 깊은 연구가 필요할 것으로 보인다. 또한, 더 다양한 테스트 시나리오에 적용하여 다양한 task에서 모델 적용성과 효과에 관한 추가적인 연구가 요구된다. 셋째로, 강화학습 환경의 상태, 보상 파라미터를 적절히 변경함으로써 통제 변인을 명확히 할 수 있으며, 다양한 운전자의 습성 또한 동시에 고려할 수 있는 후속 연구가 가능하다. 마지막으로, CarMaker 내에서 제공하는 이미지 데이터를 활용한다면[7] 실제 자율주행과 더 유사한 모델을 구현할 수 있을 것으로 보인다.

## 5. 결론

본 연구는 차량 시뮬레이션에서 강화학습의 잠재력을 강조하며, 기존 모델보다 더 정확하고 현실적인 대안을 제시한다. 연구 결과의 이러한 접근 방식은 특히 복잡한 동적 제어가 필요한 시나리오에서 기여할 수 있다. 연구의 결론은 다음과 같다:

첫째, CarMaker 환경에서 적용 가능한 강화학습 모델을 제작하였다.

둘째, 강화학습 운전자 모델이 IPG 운전자 모델보다 높은 성능을 보였다. Slalom 테스트 시나리오에서 y축 이동량에서 54 %의 성능 향상을 보였으며, ISO 3888-2 (Lane change) 시나리오에서 콘 충돌 횟수를 감소시켰다.

셋째, 다양한 task에서도 강화학습 운전자 모델이 성공적으로 적용할 수 있음을 보였다. 차량 제어에 유리한 RWS 시스템을 적용한 차량의 경우 ISO 3888-2 시나리오에서 콘 충돌이 0 회였으며, RWS 시스템이 미적용된 차량의 경우 콘 충돌이 1회로 나타났다. 반면, IPG 운전자 모델의 경우 콘 충돌이 3회로 나타났다.

## 참고문헌


(1) Kim, H.., et al. (2020). A Study on the Development and Correlation of Full Vehicle Model for Virtual Vehicle Dynamics Simulation Using CarMaker. Korea Automotive Technology Institute.

(2) Cheok Jun Hong, Vimal Rau Apraow (2021), System configuration of human-in-loop simulation for Level 3 autonomous vehicle using IPG CarMaker, IEEE International Conference on Internet of Things and Intelligence Systems, pp.215-221

(3) Tuomas Haarnoja., et al, Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor, arXiv:1801.01290v2, 2018.

(4) Sampo Kuutti., et al (2019), End-to-end reinforcement learning for autonomous longitudinal control using advantage actor critic with temporal context, IEEE Intellgent Transportation Systems Conference, pp.2456-2462

(5) Feng Mao, Zhiheng Li, Li Li. (2022), A Comparision of Deep Reinforcement Learning Models for Isolated Traffic Signal Control, IEEE intelligent Trasnportation System Magazine, January/February 2023, 10.1109

(6) H.Yong., et al (2023), Suspension control strategies using switched soft actor-critic models for real roads, in IEEE Transactions on Industrial Electronics, pp.824-832

(7) Inuzuka, S., Zhang, B., & Shen, T. (2021), Real-time HEV energy management strategy considering road congestion based on deep reinforcement learning. energies, 2021,14.